

manufacturing-quality-prediction

تحلیل و بررسی نتایج آماری و نحوه توزیع فیچرها در دیتاست ۱۷۲:

مقدمه

هدف از انجام این پروژه پیشبینی کیفیت محصولات ساخته شده در یک کارخانه مهندسی است. مدل با در نظر گرفتن ویژگی‌های ورودی نظیر شکل ابزار، سرعت چرخش ابزار و سرعت نفوذ آن‌ها درون ماده، پیشبینی می‌کند که محصول نهایی چه کیفیتی خواهد داشت؛ برای بررسی کیفیت نهایی محصولات، مواردی از جمله سختی ماده، اینکه ماده با چه سرعتی در اثر اصطکاک از بین می‌رود. یا اینکه تغییر شکل نسبی ماده نسبت به حالت اولیه چه میزان است پیشبینی می‌شوند.

برای انجام این پروژه پس از پیش‌پردازش داده‌ها ابتدا مدل‌های متنوعی را آموزش می‌دهیم و سپس ۳ مورد از بهترین مدل‌ها را از نظر دقت و پایداری و عدم بیش‌برازش انتخاب خواهیم کرد تا در ادامه با تنظیم پارامترها دقت آن‌ها را افزایش دهیم. و مشخص کنیم که رابطه ورودی‌ها با خروجی‌ها چگونه است و هر ورودی چه تاثیری بر خروجی‌ها دارد و برای پیشبینی هر خروجی کدام مدل عملکرد بهتری از خود نشان می‌دهد.

ماژول ۱- نمایش اولیه دیتاست

در گام نخست از اجرای این پروژه، دیتاست مدنظر را نمایش می‌دهیم تا با ساختار کلی آن آشنا شویم. این مرحله در واقع بخشی از EDA اولیه می‌باشد. در همین مرحله درمی‌یابیم که این پروژه یک مسئله Multi-output Regression است چراکه چندین خروجی عددی به‌عنوان تابع هدف در نظر گرفته شده‌اند.

	No.	Tool Shape	Rotational Speed	Plunging Speed	Composite Volume Fraction (%)	0	SI Particle Size (um)	Hardness (HV)	wear rate	Ultimate Compression Strength (MPa)	Elongation (%)
0	1	1	315	25.000000	0		2.900000	75.000000	8.620000	118.000000	13.500000
1	2	1	315	31.500000	0		3.400000	72.000000	9.310000	135.000000	13.000000
2	3	1	315	40.000000	0		4.100000	69.000000	10.420000	119.000000	7.500000
3	4	1	500	25.000000	0		2.200000	81.000000	8.150000	115.000000	12.000000
4	5	1	500	31.500000	0		2.700000	75.000000	8.540000	136.000000	13.000000
5	6	1	500	40.000000	0		3.200000	72.000000	9.280000	140.000000	17.000000
6	7	1	630	25.000000	0		1.400000	83.000000	7.024000	101.000000	9.700000
7	8	1	630	31.500000	0		1.600000	81.000000	7.660000	125.000000	9.500000
8	9	1	630	40.000000	0		2.000000	78.000000	8.107000	138.700000	14.000000
9	10	1	800	25.000000	0		1.100000	84.000000	6.900000	98.000000	8.300000
10	11	1	800	31.500000	0		1.300000	82.000000	7.440000	114.700000	9.100000
11	12	1	800	40.000000	0		1.500000	81.000000	7.910000	120.600000	11.000000
12	13	2	315	25.000000	0		2.300000	79.000000	8.190000	126.000000	15.000000
13	14	2	315	31.500000	0		2.700000	75.600000	8.850000	144.000000	12.000000
14	15	2	315	40.000000	0		2.800000	72.500000	10.000000	137.000000	8.000000
15	16	2	500	25.000000	0		1.800000	83.000000	7.700000	123.000000	13.200000
16	17	2	500	31.500000	0		2.200000	78.000000	8.100000	145.500000	13.500000
17	18	2	500	40.000000	0		2.600000	75.500000	8.830000	154.000000	18.700000
18	19	2	630	25.000000	0		1.100000	87.200000	6.670000	108.000000	10.700000

۱- نمایش اولیه چند سطر از دیتاست

همانطور که مشاهده می‌شود خروجی‌ها مقیاس‌های متفاوت دارند و همچنین مسئله برای مقایسه Single-output و Multi-output مناسب است.

در گام دوم همچنان در فاز EDA هستیم و آمار توصیفی و همچنین نرمال بودن داده‌ها را مورد بررسی قرار می‌دهیم.

توزیع مربوط به هر فیچر و تمرکز یا پراکندگی داده‌ها برای هر ستون مشخص خواهند شد و در این مرحله تصمیم گرفته می‌شود که آیا داده‌ها نیازی به نرمال‌سازی دارند و یا خیر.

ماژول ۲- بررسی آمار توصیفی و تست نرمال بودن برای فیچرها

--- Descriptive Statistics Table ---										
	Mean	Median	Mode	Std Dev	Variance	Skewness	Kurtosis	CI_Lower	CI_Upper	
Tool Shape	2.000	2.000	1.000	0.822	0.676	0.000	-1.521	1.807	2.193	
Rotational Speed	561.250	565.000	315.000	178.812	31973.768	-0.056	-1.252	519.231	603.269	
Plunging Speed	32.167	31.500	25.000	6.185	38.254	0.165	-1.521	30.713	33.620	
Composite Volume Fraction (%)	0.500	0.500	0.000	0.504	0.254	0.000	-2.058	0.382	0.618	
Si Particle Size (um)	1.191	0.840	0.400	0.940	0.883	1.061	0.313	0.971	1.412	
Hardness (HV)	83.527	83.750	81.000	6.175	38.132	-0.069	-0.528	82.076	84.978	
wear rate	6.711	6.559	7.000	1.454	2.114	0.399	-0.611	6.369	7.053	
Ultimate Compression Strength (MPa)	139.678	140.000	128.000	19.209	368.971	0.036	-0.344	135.164	144.192	
Elongation (%)	13.432	13.100	11.000	3.263	10.644	0.596	0.232	12.665	14.198	

۲- آمار توصیفی فیچرها در دیتاست

نزدیک بودن دو شاخص میانگین و میانه به یکدیگر نشان دهنده توزیع تقریباً متقارن و نسبتاً نرمال برای یک فیچر است. متغیرهای Hardness و UCS و Elongation دارای این ویژگی هستند و می‌توان در همین مرحله ادعا کرد که این متغیرها دارای توزیع نامتقارن شدیدی نیستند. همچنین مشاهده می‌شود که بیشتر مقادیر skewness در بازه‌ای نسبتاً کوچک‌اند، بنابراین بیشتر متغیرها چولگی شدید ندارند. Kurtosis نزدیک به صفر نیز نشان‌دهنده این است که توزیع‌ها شدیداً تخت‌تر یا نوک‌تیزتر از حد نرمال نیستند.

متغیر Tool Shape یک متغیر کیفی و nominal است و اجرای آزمون نرمال بودن برای آن بی‌معنی بوده و به‌دنبال نرمال بودن توزیع آن نیستیم.

همچنین برای فیچر Composite Volume Fraction (%) نیز دو مقدار ثابت ۰ و ۱ گزارش شده؛ در این پروژه دو عدد باینری ۰ و ۱ را معادل درصد فیزیکی ۰٪ و ۱٪ اعلام می‌داریم، بنابراین One Hot Encoding برای این متغیر نیازی نیست. اما در نهایت مدل فقط می‌تواند اثر خطی این فاکتور را برآورد کند و قادر به تشخیص هرگونه رابطه غیرخطی (مثل انحنا یا نقطه بهینه) در این بازه نخواهد بود.

✓ وجود فیچرهای غیرنرمال و یا با ماهیت گسسته باعث می‌شود مدل‌های یادگیری مبتنی بر درخت نتایج خوبی روی چنین دیتاستی داشته باشند.

	Shapiro_p	KS_p	Normal
Feature			
Tool Shape	1.120639e-08	1.401253e-03	False
Rotational Speed	1.054947e-06	3.380466e-02	False
Plunging Speed	8.458760e-09	7.511960e-04	False
Composite Volume Fraction (%)	4.575570e-12	6.472595e-08	False
Si Particle Size (um)	3.162229e-06	3.683280e-02	False
Hardness (HV)	7.748489e-01	9.930271e-01	True
wear rate	5.205504e-02	6.761680e-01	True
Ultimate Compression Strength (MPa)	9.661656e-01	9.999978e-01	True
Elongation (%)	9.619153e-02	4.680571e-01	True

۳- نتیجه آزمون نرمال بودن توزیع فیچرها

آزمون Shapiro-Wilk و آزمون Kolmogorov-Smirnov با هدف بررسی اینکه آیا توزیع یک متغیر نرمال هست یا خیر انجام شدند. در این دو آزمون مقدار p-value نرمال بودن هر توزیع را رد و یا تایید می‌کند.


فیچرهایی نظیر Plunging Speed و Rotational Speed غیرنرمال به نظر می‌رسند چراکه ستون normal برای این فیچرها false را نشان می‌دهد که بیانگر $p \leq 0.05$ برای آن فیچر است؛ اما این موضوع محدودیتی برای ما ایجاد نخواهد کرد؛

✓ چراکه فیچرهای ورودی این دیتاست ماهیت گسسته و سطح‌بندی‌شده‌ای دارند و غیرنرمال تشخیص داده شدن آن‌ها خللی در آموزش مدل‌ها ایجاد نمی‌کند. آن‌ها را Numeric در نظر گرفته و به Scale کردن آن‌ها درون پایپلاین خواهیم پرداخت.


ماژول ۳- بررسی همبستگی و رسم نمودارهای توزیع فیچرها

در نتیجه بررسی همبستگی‌ها، میان خروجی‌ها همبستگی شدیدی دیده می‌شود که بدان معنی است که خروجی‌ها با یکدیگر رابطه داشته و بر روی یکدیگر تاثیر می‌گذارند؛ بنابراین باید برای چنین دیتاست‌هایی از مدل‌های Multi-output استفاده کرد. این مدل‌ها به جای پیشبینی جداگانه هر خروجی، وابستگی بین آن‌ها را یاد گرفته و با توجه به وجود وابستگی پیشبینی بهتری ارائه خواهند داد.

در نتایج همبستگی Pearson مشاهده می‌شود که همبستگی‌های پایداری وجود دارد؛ این همبستگی‌ها را می‌توان میان نرخ سایش و اندازه ذرات مشاهده کرد. می‌دانیم که میان متغیرها، برخی از آنان غیرنرمال هستند؛ به همین دلیل انتظار می‌رود متد Spearman نتایج دقیق‌تری را نشان دهد.




۴- همبستگی Pearson برای بررسی روابط خطی



۵- همبستگی Spearman برای بررسی روابط یکنوا


در نتایج همبستگی Spearman مشاهده می‌شود که الگوی کلی این ماتریس بسیار شبیه متد Spearman است؛ قوی‌ترین رابطه در دیتاست، متعلق به رابطه اندازه ذرات با نرخ سایش است؛ و هرچه اندازه ذرات ورودی بزرگتر باشد در نتیجه نرخ سایش ماده خروجی بیشتر خواهد بود.

همچنین دو همبستگی قوی منفی دیده می‌شود یکی میان Composite Volume Fraction و اندازه ذرات؛ و در رتبه سوم، میان Composite Volume Fraction و نرخ سایش.




۶- همبستگی Kendall برای بررسی سختگیرانه‌تر روابط رتبه‌ای

رتبه‌بندی همبستگی‌ها در هر سه متد یکسان دیده شد؛ تنها تفاوت اصلی میان مقادیر همبستگی‌ها بود؛ می‌دانیم متد Kendall به دلیل ماهیت سختگیرانه‌تری که دارد مقادیر کوچک‌تری را نسبت به دو روش قبل نشان می‌دهد و این امری طبیعی است.




۷- نمودارهای توزیع مربوط به ویژگی Tool Shape

در بررسی نمودارهای توزیع فیچر Tool Shape در می‌یابیم که در Boxplot داده پرت خاصی دیده نمی‌شود، زیرا داده‌ها از نوع کیفی- اسمی بوده و محدود به چند سطح مشخص‌اند تا فقط دسته‌بندی ابزار را مشخص کنند. QQ-plot نیز گسسته و پله‌ای بودن داده‌ها را تایید می‌کند.




۸- نمودارهای توزیع مربوط به ویژگی Rotational Speed

Rotational Speed نیز ماهیت گسسته دارد و به چند درجه سرعت خاص اشاره دارد؛ برای این متغیر ۴ سطح مجزا در هر سه نمودار مشاهده می‌شود که بیانگر گسسته بودن این متغیر است؛ این متغیر در محیط آزمایشگاه در سطوح مختلف طبقه بندی شده است.




۹- نمودارهای توزیع مربوط به ویژگی Plunging Speed

ویژگی ورودی Plunging Speed نیز در محیط آزمایشگاه در ۳ سطح طبقه‌بندی شده است.



۱۰- نمودارهای توزیع مربوط به ویژگی Composite Volume Fraction (%)

در متغیر Composite Volume Fraction (%) تنها مقادیر ۰ و ۱ مشاهده می‌شود و همین موضوع سبب شده تا شکل هیستوگرام به فرم توزیع Bimodal تبدیل شود؛ طبق ماهیت فیزیکی این فیچر، ۰ و ۱ نمایانگر درصد حجمی ۰٪ و ۱۰۰٪ می‌باشند و این متغیر از نوع عددی است.




۱۱- نمودارهای توزیع مربوط به ویژگی Si Particle Size (um)

متغیر Si Particle Size (um) با توزیع پیوسته؛ که هیستوگرام نشان می‌دهد چولگی راست در توزیع آن دیده می‌شود.

Boxplot نشان‌دهنده این است که تعداد کمی ذره درشت (outlier) وجود دارد که نتیجه سرمایش آهسته و نامناسب است؛ مدل‌های مبتنی بر درخت می‌توانند outlier ها را بدون نیاز به حذف یا normalization مدل کنند

QQ-plot نشان می‌دهد توزیع غیرنرمال است.




۱۲- نمودارهای توزیع مربوط به ویژگی Hardness

هیستوگرام مربوط به این متغیر توزیع نرمالی را نشان می‌دهد. بهترین توزیع نرمال در کل دیتاست

در نمودار QQ، نقاط به خوبی روی خط قرمز قرار گرفته‌اند. این یعنی توزیع داده‌ها نرمال است.

نمودار Boxplot نشان می‌دهد که هیچ نقطه دوری وجود ندارد. این یعنی داده‌ها تمیز و باکیفیت هستند و نیازی به عملیات پیش‌پردازش پیچیده برای این ستون نیست.




۱۴- نمودارهای توزیع مربوط به ویژگی Ultimate Compression Strength

توزیع این ستون بسیار متقارن است. هیستوگرام نشان می‌دهد داده‌ها در یک بازه مشخص به صورت منطقی پخش شده‌اند.

در باکس‌پلات، خط میانه در مرکز جعبه قرار دارد و همچنین این متغیر فاقد داده‌های پرت است.


انطباق تمام نقاط روی خط قرمز در نمودار QQ Plot نیز بیانگر همین موضوع است.



۱۵- نمودارهای توزیع مربوط به ویژگی Elongation

چولگی به راست در هیستوگرام و پراکندگی نقاط بالای خط قرمز در QQ Plot نشان می‌دهند که در مقادیر بالا پیش‌بینی این تارگت پیچیده و دشوار است و دقت پایینی خواهد داشت.

همچنین باکس‌پلات نشان دهنده داده پرت در حدود ۲۲٪ است که نه تنها طبیعی است؛ بلکه بیانگر ریخته‌گری عالی است.



۱۷- نمودارهای توزیع مربوط به ویژگی Wear rate

هیستوگرام نشان دهنده چولگی به راست است؛ یعنی مقادیر مربوط به این خروجی در مقادیر بالا گسترده شده‌اند.

نقاط بالای QQ-Plot نیز نسبت به خط قرمز منحرف شده‌اند و این چولگی به راست را در هیستوگرام تصدیق می‌کند.

در باکس‌پلات نیز median به سمت Q1 نزدیک‌تر شده است. پیش‌بینی می‌شود مدل‌های غیرخطی این تارگت را بهتر از مدل‌های خطی پیش‌بینی کنند.

ماژول ۴- پیش‌پردازش داده‌ها

پس از پایان EDA در مرحله پیش‌پردازش داده‌ها، ویژگی‌های ورودی را از خروجی جدا می‌کنیم. در مراحل قبل تایید کردیم که ورودی‌ها اعداد صحیح گسسته با فواصل مشخص هستند و درون پایپلاین Scale خواهند شد.

فیچر Tool Shape به دلیل ماهیت کیفی-اسمی که دارد مستلزم Encoding است؛ اما پیش‌تر بیان کردیم که متغیر Composite Volume Fraction متغیری عددی شناخته شد و نیازی به عملیات Encoding ندارد.

همه خروجی‌ها مقادیر کاملاً پیوسته و اعشاری دارند. اما متغیر Si Particle Size به دلیل غیرنرمال بودن و چولگی شدید، دستخوش عملیات IQR Capping + log1p درون پایپلاین خواهد شد.

0.15

Constant columns: []
X shape: (72, 4)
y shape: (72, 5)

	Tool Shape	Rotational Speed	Plunging Speed	Composite Volume Fraction (%)	
0	1	315	25.0	0	
1	1	315	31.5	0	
2	1	315	40.0	0	
3	1	500	25.0	0	
4	1	500	31.5	0	

	Si Particle Size (um)	Hardness (HV)	wear rate	Ultimate Compression Strength (MPa)	Elongation (%)
0	2.9	75.0	8.62	118.0	13.5
1	3.4	72.0	9.31	135.0	13.0
2	4.1	69.0	10.42	119.0	7.5
3	2.2	81.0	8.15	115.0	12.0
4	2.7	75.0	8.54	136.0	13.0

۱۸- ابعاد دیتاست و ماهیت فیچرهای ورودی و خروجی

ماژول ۵- MLOPS PREPARATION REPORT

در این گام به آماده‌سازی مجموعه داده برای آموزش مدل پرداختیم و بخش کوچکی از داده‌ها را برای ارزیابی نهایی و Cross-Validation جداسازی کردیم.

همچنین Experiment Seeds را به منظور تضمین تکرارپذیری آزمایش‌ها تنظیم کردیم.

```
...
=== MLOps PREPARATION REPORT (Dataset 0172) ===
Features: 4 | Samples: 72
Categorical: ['Tool Shape']
Numeric (incl. Rotational Speed): ['Rotational Speed', 'Plunging Speed', 'Composite Volume Fraction (%)']
Log-transformed targets: ['Si Particle Size (um)']
```

۱۹- خروجی گزارش اولیه MLOPS

گزارش اولیه MLOPS حجم کل داده‌های موجود را نشان داده و عملیات $\log_{1p}$ + IQR Capping برای متغیر Si Particle Size جهت رفع غیرنرمال بودن را تایید می‌کند.

Rotational Speed و Composite Volume Fraction و Plunging Speed طبق این گزارش Numeric Features در نظر گرفته شده و باید Scale شوند.

گفته بودیم که ویژگی Tool Shape باید One Hot Encoded شود؛ در همین راستا ستون مربوط به این ویژگی به دو ستون که هر کدام نماینده مقدار باینری ۰ و ۱ هستند تقسیم می‌شود و در نهایت تعداد ستون‌های ورودی از ۴ به ۵ تا تبدیل خواهد شد.

✓ نکته حائز توجه این است که Preprocessing ورودی‌ها و IQR Capping را درون حلقه KFold انجام دادیم تا از نشت داده جلوگیری شود.

ماژول ۶ و ۷ و ۸- تنظیمات اولیه برای آموزش مدل‌ها

مشخص کردن EARLY STOP MODELS برای کنترل Over fitting در مدل‌های بوستینگ انجام شد؛ چراکه چنین مدل‌هایی به دلیل داشتن iteration های زیاد روی داده‌های آموزش، دچار بیش‌برازش شده و این داده‌ها را با تمام جزئیات یاد می‌گیرند.

در ماژول بعدی توابع ارزیابی که در پروژه خواسته شده بودند را تعریف کردیم. از چند شاخص مکمل استفاده شد:

R2 برای سنجش میزان توضیح‌پذیری و RMSE/MAE برای اندازه‌گیری خطا استفاده شده‌اند. از شاخص NRMSE به منظور مقایسه بین خروجی‌های مختلف استفاده می‌شود.

ماژول ۹- تابع ساخت Cross Validation

نمونه‌ها قبل از تقسیم shuffle می‌شوند و سپس از KFold برای تقسیم داده‌ها به چند بخش استفاده می‌شود؛ داده‌ها به ۵ بخش ۸ تایی تقسیم می‌شوند و در هر Iteration ۲۸ یا ۲۹ داده (۸۰٪ داده‌ها) برای یادگیری مدل استفاده می‌شود و ۷ یا ۸ داده باقی‌مانده (۲۰٪ داده‌ها) برای ارزیابی مدل کنار گذاشته می‌شود. در نهایت این عملیات ۵ بار تکرار می‌شود تا هر داده دقیقاً یک بار در بخش تست قرار گیرد.

ماژول ۱۱- ساخت پایپ‌لاین مدل‌سازی

به کمک Pipeline مراحل آماده‌سازی داده و آموزش مدل را در یک زنجیره واحد قرار می‌دهیم تا همه‌چیز در هر اجرا به‌صورت خودکار، منظم و بدون خطا انجام شود.

ماژول ۱۲- اجرای کامل فرآیند یادگیری مدل و پیش‌بینی خروجی‌ها

در هر Fold پایپ‌لاین یکپارچه زیر تکرار خواهد شد:

۱- نرمال‌سازی متغیرهای عددی و one hot encoding متغیر کیفی-اسمی

۲- آموزش مدل

۳- مدل برای ۷ داده‌ی تستی خروجی را پیش‌بینی می‌کند.

۴- مقادیر پیش‌بینی شده با مقادیر واقعی مقایسه شده و معیارهای RMSE و R2 محاسبه می‌شوند.

ماژول ۱۳- آموزش اختصاصی مدل‌های LightGBM و XGBoost

در مدل‌های XGBoost و LightGBM به دلیل ماهیتی که دارند، آموزش به‌صورت اختصاصی انجام می‌شود.

داده‌های آموزش به دو بخش Training و Validation تقسیم می‌شوند و Early Stopping باعث می‌شود هر زمان در حین آموزش، بهبود عملکرد مجموعه Validation متوقف شد، فرآیند آموزش متوقف شود.

همچنین این مدل‌ها به دلیل داشتن iteration های زیاد پایپلاین ندارند و به منظور جلوگیری از Data Leakage نرمال‌سازی متغیرهای عددی و one hot encoding متغیر کیفی-اسمی به صورت دستی انجام می‌شود.

ماژول ۱۴- Orchestrator Function

باتوجه به موارد بیان شده، این تابع تصمیم می‌گیرد که با توجه به ماهیت مدل که از نوع استاندارد است و یا Boosting چه استراتژی برای آموزش در پیش گرفته شود.

ماژول ۱۵ و ۱۶- ثبت شاخص‌های ارزیابی در MLflow

شاخص‌هایی مانند R2 که ملاک اصلی رتبه‌بندی میان مدل‌ها است، به صورت جداگانه برای هر فولد در MLflow ثبت خواهند شد.

ماژول ۱۷- اجرای کامل فرآیند Cross Validation

این تابع حلقه اصلی اجرای آزمایش‌هاست که ۵ بار تکرار می‌شود تا تمام داده‌ها تست شوند؛ طبق الگوی رایج، ۶۴٪ داده‌ها جهت آموزش و ۱۶٪ داده‌ها برای اعتبارسنجی استفاده خواهند شد.

ماژول ۱۸- اجرای کامل فرآیند ارزیابی یک مدل روی یک ستون هدف

به ازای هر ستون هدف همانند Ultimate Compression Strength (MPa) در MLflow یک run جدا ساخته می‌شود که درون آن نتایج مربوط به پیش‌بینی مدل از این ستون ثبت خواهد شد. هر مدل برای هر خروجی، شناسنامه و گزارش جداگانه‌ای خواهد داشت.

تابع run_model_for_target عملیات‌های زیر را برای یک ستون هدف اجرا خواهد کرد:

۱- اجرای cross validation

۲- جداسازی داده‌های آموزش و اعتبارسنجی در هر fold

۳- preprocessor را fit می‌کند.

۴- مدل را آموزش می‌دهد

۵- هدف را پیش‌بینی می‌کند.

۶- metric ها را حساب می‌کند.

ماژول ۱۹- مدیریت اجرای مدل‌ها برای یک ستون هدف

تابع run_all_models_for_target عملیات زیر را اجرا خواهد کرد:

۱- یک ستون هدف را انتخاب می‌کند.

۲- همه مدل‌های ساخته شده را فراخوانی می‌کند.

۳- برای هر مدل همه seed ها را می‌چرخاند.

۴- به ازای هر ترکیب، run_model_for_target را فراخوانی می‌کند.

۵- نتایج را جمع‌آوری می‌کند.

ماژول ۲۰- محاسبه میانگین شاخص‌ها برای هر مدل

در این بخش برای هر مدل، میانگین هر شاخص در تمام fold ها محاسبه خواهد شد تا عملکرد و دقت مدل‌ها با یکدیگر قابل مقایسه شود.

ماژول ۲۱- اجرای کامل آزمایش برای متغیر هدف و ثبت نتایج

```
=====
Target: Si Particle Size (um)
=====
Linear Regression | seed=42 | fold=1 | R2=0.8837 | RMSE=0.3202 | NRMSE=0.1097 | MAE=0.2307
Linear Regression | seed=42 | fold=2 | R2=0.8763 | RMSE=0.1887 | NRMSE=0.0943 | MAE=0.1591
Linear Regression | seed=42 | fold=3 | R2=0.9429 | RMSE=0.2123 | NRMSE=0.0856 | MAE=0.1676
Linear Regression | seed=42 | fold=4 | R2=0.9692 | RMSE=0.1408 | NRMSE=0.0504 | MAE=0.1058
Linear Regression | seed=42 | fold=5 | R2=0.9596 | RMSE=0.2217 | NRMSE=0.0710 | MAE=0.1543
Ridge | seed=42 | fold=1 | R2=0.8673 | RMSE=0.3420 | NRMSE=0.1171 | MAE=0.2433
Ridge | seed=42 | fold=2 | R2=0.8783 | RMSE=0.1871 | NRMSE=0.0936 | MAE=0.1576
Ridge | seed=42 | fold=3 | R2=0.9463 | RMSE=0.2060 | NRMSE=0.0831 | MAE=0.1563
Ridge | seed=42 | fold=4 | R2=0.9687 | RMSE=0.1418 | NRMSE=0.0508 | MAE=0.1056
Ridge | seed=42 | fold=5 | R2=0.9490 | RMSE=0.2490 | NRMSE=0.0797 | MAE=0.1657
ElasticNet | seed=42 | fold=1 | R2=0.8330 | RMSE=0.3837 | NRMSE=0.1314 | MAE=0.2708
ElasticNet | seed=42 | fold=2 | R2=0.8756 | RMSE=0.1892 | NRMSE=0.0946 | MAE=0.1577
ElasticNet | seed=42 | fold=3 | R2=0.9513 | RMSE=0.1961 | NRMSE=0.0791 | MAE=0.1499
ElasticNet | seed=42 | fold=4 | R2=0.9688 | RMSE=0.1416 | NRMSE=0.0507 | MAE=0.0979
ElasticNet | seed=42 | fold=5 | R2=0.9309 | RMSE=0.2900 | NRMSE=0.0929 | MAE=0.1862
SVR (RBF) | seed=42 | fold=1 | R2=0.8751 | RMSE=0.3318 | NRMSE=0.1136 | MAE=0.2560
SVR (RBF) | seed=42 | fold=2 | R2=0.8942 | RMSE=0.1745 | NRMSE=0.0873 | MAE=0.1538
SVR (RBF) | seed=42 | fold=3 | R2=0.9641 | RMSE=0.1684 | NRMSE=0.0679 | MAE=0.1273
SVR (RBF) | seed=42 | fold=4 | R2=0.9493 | RMSE=0.1804 | NRMSE=0.0647 | MAE=0.1543
SVR (RBF) | seed=42 | fold=5 | R2=0.9536 | RMSE=0.2375 | NRMSE=0.0761 | MAE=0.1557
GPR (Kriging) | seed=42 | fold=1 | R2=0.9785 | RMSE=0.1377 | NRMSE=0.0471 | MAE=0.1026
...
ANN (MLP) | seed=888 | fold=4 | R2=-0.3947 | RMSE=3.5676 | NRMSE=0.3273 | MAE=3.2507
ANN (MLP) | seed=888 | fold=5 | R2=-1.1591 | RMSE=3.4337 | NRMSE=0.3947 | MAE=2.9036
=====
All experiments completed.
```

۲۰- اجرای مدل‌ها روی ستون هدف Si Particle Size (um)

	target	model	seed	mean_R2	std_R2	mean_RMSE	mean_NRMSE	mean_MAE
0	Si Particle Size (um)	Linear Regression	42	0.926328	0.038828	0.216730	0.082212	0.163495
1	Si Particle Size (um)	Ridge	42	0.921917	0.040987	0.225193	0.084867	0.165688
2	Si Particle Size (um)	ElasticNet	42	0.911901	0.050391	0.240128	0.089744	0.172500
3	Si Particle Size (um)	SVR (RBF)	42	0.927265	0.035642	0.218523	0.081903	0.169431
4	Si Particle Size (um)	GPR (Kriging)	42	0.977960	0.007802	0.127323	0.046976	0.084117

۲۱- بررسی شاخص R2 مدل‌های مختلف برای ستون هدف Si Particle Size (um)

هرچه شاخص R^2 عدد بزرگتری داشته باشد مدل از نظر دقت عملکرد بهتری داشته است بنابراین مدل GPR براساس این معیار، بهترین عملکرد را داشته و در رتبه دوم مدل SVR قرار دارد که به دلیل محاسبات سنگین پیشنهاد نمی‌شود؛ مدل ANN نیز در تصویر اول عملکرد قابل قبولی داشته چراکه این مدل روابط غیرخطی پیچیده را به خوبی یاد می‌گیرد.

بهتر است علاوه بر میانگین، به انحراف معیار R^2 نیز توجه کنیم؛ کمتر بودن معیار std_R^2 نشان می‌دهد که آن مدل بین fold های مختلف، عملکرد پایدارتری داشته، بنابراین مدل GPR (Kriging) بیشترین پایداری را از خود نشان داده است. در مقابل مدل‌های خطی نظیر Linear Regression و Ridge عملکرد قابل قبولی از خود نشان ندادند.

✓ دلیل برتری مدل این است که GPR یک مدل برون‌یابی (Interpolation) بسیار قدرتمند است که در فضای داده‌های آزمایشگاهی کم‌تعداد مانند این دیتاست بسیار عالی عمل می‌کند. این مدل نه تنها داده‌ها را می‌بیند، بلکه توزیع احتمالاتی را هم در نظر می‌گیرد.

ماژول ۲۲- Decision Engineering

در این پروژه تنها هدف ما بهبود و افزایش معیار R^2 نبود، بلکه به دنبال مدلی پایدار با دقت بالا و پرهیز از بیش‌برازش بودیم؛ بنابراین در این فاز از پروژه تمام ستون‌های هدف را توسط تمام مدل‌ها پیش‌بینی کرده و از یک معیار ترکیبی برای رتبه‌بندی مدل‌ها استفاده کردیم.

ساخت پایپلاین با موفقیت انجام شده و اکنون سه مدل برتر به ازای هر ستون هدف را یافتیم.

✓ و نکته حائز اهمیت اینجاست که مدلی که در طول Cross Validation، عملکرد پایدار و قابل اعتمادی دارد انتخاب شده است؛ و تمرکز صرفاً بر روی Accuracy نمی‌باشد.

	target	model	mean_R2	std_R2	Overall_Score
10	Elongation (%)	XGBoost	0.725800	0.155072	0.949659
4	Elongation (%)	Gradient Boosting	0.684587	0.111820	0.927459
9	Elongation (%)	SVR (RBF)	0.561879	0.153121	0.807252
17	Hardness (HV)	Linear Regression	0.902769	0.053499	0.982098
12	Hardness (HV)	ElasticNet	0.902552	0.053219	0.977076
19	Hardness (HV)	Ridge	0.899700	0.053445	0.975692
26	Si Particle Size (um)	Gradient Boosting	0.978660	0.011243	0.970000
27	Si Particle Size (um)	LightGBM	0.973446	0.013780	0.932287
32	Si Particle Size (um)	XGBoost	0.972462	0.015598	0.923996
43	Ultimate Compression Strength (MPa)	XGBoost	0.870211	0.065827	0.963338
37	Ultimate Compression Strength (MPa)	Gradient Boosting	0.854161	0.074050	0.955443
38	Ultimate Compression Strength (MPa)	LightGBM	0.834985	0.087957	0.936831
54	wear rate	XGBoost	0.975782	0.014209	0.961633
49	wear rate	LightGBM	0.975584	0.014154	0.958100
48	wear rate	Gradient Boosting	0.971914	0.014496	0.949479

۲۲- بررسی شاخص R^2 مدل‌های مختلف روی همه ستون‌های هدف

دقت پیش‌بینی کسب شده توسط مدل‌ها به ترتیب زیر است؛ دلایل فیزیکی این ترتیب قبل‌تر توضیح داده شده.

Si Particle Size > Wear Rate $\approx$ Hardness > UCS > Elongation

به بیان خلاصه تارگتهایی با روابط پیچیده، توسط مدل‌های مبتنی بر درخت بهتر مدل شده‌اند.

در Hardness رتبه‌های اول تا سوم را مدل‌های خطی (Linear Regression, ElasticNet, Ridge) کسب کرده‌اند چراکه این متغیر در علم فیزیک تابعی خطی از چندین ویژگی ورودی ساده است.

ماژول ۲۳ – Initial Hyperparameter Optimization

پس از اجرای تمام مدل‌ها حال وارد فاز انتخاب مدل می‌شویم. این همان فاز Decision Engineering است.

میخواهیم بدانیم برای هر ستون هدف، کدام مدل را باید نگه داشته شود و بهترین پارامترها برای آن مدل چیست.

	target	model	best_params	best_r2_score
0	Elongation (%)	XGBoost	{'regressor_subsample': 0.7, 'regressor_n_es...	0.718047
1	Elongation (%)	Gradient Boosting	{'regressor_subsample': 0.7, 'regressor_n_es...	0.678499
2	Elongation (%)	SVR (RBF)	{}	N/A
3	Hardness (HV)	Linear Regression	{}	N/A
4	Hardness (HV)	ElasticNet	{'regressor_l1_ratio': 0.4555555555555556, 'r...	0.877725
5	Hardness (HV)	Ridge	{'regressor_alpha': 0.3727593720314938}	0.87789
6	Si Particle Size (um)	Gradient Boosting	{'regressor_subsample': 0.7, 'regressor_n_es...	0.990774
7	Si Particle Size (um)	LightGBM	{}	N/A
8	Si Particle Size (um)	XGBoost	{'regressor_subsample': 0.7, 'regressor_n_es...	0.982976
9	Ultimate Compression Strength (MPa)	XGBoost	{'regressor_subsample': 0.7, 'regressor_n_es...	0.88606
10	Ultimate Compression Strength (MPa)	Gradient Boosting	{'regressor_subsample': 0.7, 'regressor_n_es...	0.878573
11	Ultimate Compression Strength (MPa)	LightGBM	{}	N/A
12	wear rate	XGBoost	{'regressor_subsample': 0.7, 'regressor_n_es...	0.977839
13	wear rate	LightGBM	{}	N/A
14	wear rate	Gradient Boosting	{'regressor_subsample': 0.7, 'regressor_n_es...	0.978067

۲۳- نتایج مدل‌ها پس از بهینه‌سازی اولیه

Gradient Boosting در بهینه‌سازی اولیه Optuna برای اکثر تارگت‌ها نتیجه خوبی داشت.

mean_R2 نسبت به best_r2_score که در این جدول وجود دارد معیار قابل اعتمادتری است؛

✓ در متغیر Si Particle Size شاخص best_r2_score تقریباً کامل شده که می‌تواند به دلیل overfitting

روی validation fold خاصی در طول tuning باشد؛ بنابراین برای هر تارگت باید mean_R2 را به‌عنوان

دقت به‌دست آمده گزارش کنیم.

ماژول ۲۴ – Bayesian Optimization

به کمک Bayesian Optimization برای مدل‌های منتخب گام قبل، پارامترهای دقیق‌تری تنظیم می‌کنیم؛

ستون best_params جدید، از جستجوی خودکار به‌دست آمده است و در این فاز به جای مقایسه بین مدل‌ها، از بین بهترین

ورژن مدل‌ها انتخاب را انجام می‌دهیم.

نتایج Hyperparameter Tuning را در جدول زیر نمایش می‌دهیم:

	target	model	best_r2_optuna	best_params
0	Elongation (%)	XGBoost	0.7373	{'n_estimators': 55, 'learning_rate': 0.170526...
1	Elongation (%)	Gradient Boosting	0.6663	{'n_estimators': 165, 'learning_rate': 0.09681...
2	Elongation (%)	SVR (RBF)	0.4866	{}
3	Hardness (HV)	Linear Regression	0.8773	{}
4	Hardness (HV)	ElasticNet	0.8778	{'alpha': 0.006299109534128049, 'l1_ratio': 0...
5	Hardness (HV)	Ridge	0.8778	{'alpha': 0.5327870491669573}
6	Si Particle Size (um)	Gradient Boosting	0.9891	{'n_estimators': 233, 'learning_rate': 0.04560...
7	Si Particle Size (um)	LightGBM	0.9847	{}
8	Si Particle Size (um)	XGBoost	0.9838	{'n_estimators': 153, 'learning_rate': 0.11940...
9	Ultimate Compression Strength (MPa)	XGBoost	0.8939	{'n_estimators': 153, 'learning_rate': 0.11940...
10	Ultimate Compression Strength (MPa)	Gradient Boosting	0.8550	{'n_estimators': 168, 'learning_rate': 0.04928...
11	Ultimate Compression Strength (MPa)	LightGBM	0.8881	{}
12	wear rate	XGBoost	0.9820	{'n_estimators': 153, 'learning_rate': 0.11940...
13	wear rate	LightGBM	0.9824	{}
14	wear rate	Gradient Boosting	0.9751	{'n_estimators': 99, 'learning_rate': 0.099104...

۲۴- نتایج مدل‌ها پس از بهینه‌سازی Bayesian

تغییرات ایجاد شده به شرح زیر است:

دقت تارگت‌های Wear Rate و UCS و Elongation افزایش یافت همچنین بهترین مدل برای پیش‌بینی متغیر Wear Rate از light GBM به XGBoost تغییر پیدا کرد.

LightGBM در تمام target ها skip شده است؛ و دلیل این اتفاق تنظیمات پیچیده‌تر در search space این بهینه‌ساز و یا محدودیت زمانی بود.

✓ برای دیتاست‌های کوچکی که دقت در آن‌ها از سرعت مهم‌تر است؛ بهینه‌سازی Bayesian پیشنهاد می‌شود.

ماژول ۲۵- Feature Importance

مدل‌ها قبلاً مقایسه شده‌اند سپس با Optuna و بهینه‌ساز Bayesian تیون شده‌اند و بهترین مدل هر تارگت انتخاب شده، اکنون تحلیل نهایی و تفسیر ویژگی‌ها در حال انجام است.

در این گام بهترین مدل نهایی برای هر تارگت انتخاب می‌شود.

	target	model	best_r2_optuna
0	Si Particle Size (um)	Gradient Boosting	0.9891
1	wear rate	LightGBM	0.9824
2	Ultimate Compression Strength (MPa)	XGBoost	0.8939
3	Hardness (HV)	ElasticNet	0.8778
4	Elongation (%)	XGBoost	0.7373

۲۵- بهترین مدل برای پیشبینی هر ستون هدف

غلبه مدل‌های Boosting در اکثر تارگت‌ها مشهود است؛ این موضوع بیانگر آن است که رابطه بین ورودی‌ها و خروجی‌ها نسبتاً غیرخطی و پیچیده بوده و ساختار داده‌های این دیتاست قابل تفسیر و پیشبینی است.

ماژول ۲۶- Feature Importance

در این فاز ۳ مورد را برای هریک از ویژگی‌ها بررسی می‌کنیم:


۱- اهمیت کلی هر ویژگی در کل دیتاست (Global Importance)

۲- جهت و شدت اثر هر ویژگی روی خروجی (SHAP Summary)


۳- توضیح پیش‌بینی یک نمونه خاص (SHAP Local)

✓ این موضوع که **SHAP Local** با افزایش یک ویژگی، روی خروجی گاهی تاثیر مثبت و گاهی تاثیر منفی داشته باشد، با خطی بودن رابطه آن دو ورودی و خروجی سازگار است؛ چراکه خطی بودن یک رابطه که توسط مدل‌های خطی خیلی دقیق پیش‌بینی می‌شود، به معنی این است که با افزایش ورودی، خروجی هم افزایش می‌یابد و بالعکس.


✓ اما **SHAP** بیان می‌کند که این ویژگی در این نمونه، نسبت به حالت متوسط، خروجی را بالا برده یا پایین آورده؟




ویژگی **Ultimate Compression Strength** یا همان استحکام فشاری نهایی عمدتاً تحت تاثیر سرعت نفوذ است و سرعت چرخش نیز در تبه سوم تاثیرگذاری روی آن قرار دارد، و شکل وسیله مکانیکی تاثیراتی روی استحکام فشاری نهایی ماده دارد و بی‌تاثیر نیست.




این شکل تایید می کند که افزایش Rotational Speed باعث افزایش خروجی و افزایش Plunging Speed باعث کاهش خروجی می شود و سرعت نفوذ، با استحکام فشاری رابطه عکس دارد.



در این نمونه، اگرچه Rotational Speed و Composite Volume Fraction اثر مثبت داشته اند، اما فقط Plunging Speed اثر منفی بر استحکام فشاری گذاشته. اگرچه درنهایت پیشبینی مدل از میانگین بالاتر رفته اما اگر قصد افزایش استحکام فشاری ماده را داشته باشیم حتما باید سرعت نفوذ را کنترل کنیم.




ویژگی wear rate یا همان نرخ سایش نهایی، عمدتاً تحت تأثیر حجم کامپوزیت ماده است و سرعت چرخشی در رتبه دوم تأثیر خوبی روی آن دارد، و شکل وسیله مکانیکی تأثیر کمی روی نرخ سایش نهایی ماده دارد اما بی تأثیر نیست.




رابطه منفی قوی بین درصد کامپوزیت با نرخ سایش وجود دارد؛ هرچه درصد کامپوزیت بیشتری در ماده به کار رفته باشد؛ نرخ سایش آن ماده کمتر خواهد شد.


همچنین هرچه قدر سرعت چرخش بالاتر رود به دلیل افزایش دمای ماده و نرم شدن موضع، سایش آن ماده نرخ بیشتری پیدا خواهد کرد.




در این نمونه، برآیند اثر چند متغیر را روی پیش‌بینی مدل مشاهده می‌کنیم؛ درصد کامپوزیت بکار رفته در این مدل کم بوده و سرعت چرخش نیز کم بوده، نرخ سایش نسبت به میانگین افزایش پیدا کرده است.




ویژگی Hardness یا همان سختی نهایی، عمدتاً تحت تأثیر سرعت چرخشی است و درصد کامپوزیت در رتبه دوم تأثیر خوبی روی آن دارد، شکل وسیله مکانیکی برخلاف موارد قبلی، نسبت به عامل سرعت نفوذ تأثیرگذارتر است.




سرعت چرخشی با عامل سختی رابطه بسیار قوی و مثبت دارد درحالیکه عامل سرعت نفوذ، با سختی رابطه معکوس دارد و با افزایش سرعت نفوذ سختی ماده خروجی کم می‌شود.




سرعت نفوذ در این نمونه سعی در افزایش مقدار سختی داشته، اما نتوانسته اثرات کاهنده‌ی سایر عوامل را خنثی کند. Rotational Speed و Composite Volume Fraction و Tool Shape کاهش یافته اند و سختی را کاهش داده‌اند.




ویژگی Elongation یا همان کشیدگی نهایی، به دلیل پیچیدگی که دارد، تحت تاثیر سرعت چرخشی و همچنین سرعت نفوذ است و هردو مورد نقش پررنگی در ایجاد این ویژگی دارند. و شکل وسیله مکانیکی تاثیر بسیار کمی در ایجاد این ویژگی دارد.




مقدار بالاتر عامل سرعت نفوذ عمدتاً اثر مثبت و مقدار پایین‌تر اثر منفی دارد. بنابراین، افزایش کنترل‌شده‌ی آن احتمالاً Elongation را بهتر می‌کند. بنابراین، افزایش کنترل‌شده‌ی آن احتمالاً Elongation را بهتر می‌کند. عوامل سرعت نفوذ و سرعت چرخشی و درصد کامپوزیت همگی تاثیر مثبت بر Elongation دارند.




در این نمونه، سرعت چرخش کاهش یافته و با تاثیر قوی خود سبب کاهش میانگین Elongation شده و افزایش سرعت نفوذ نتوانسته تاثیر این کاهش را خنثی کند.



در پیشبینی Si Particle Size ویژگی درصد کامپوزیت کاملاً غالب است و دلایل فیزیکی آن پیشتر توضیح داده شده اند.



افزایش درصد کامپوزیت باعث کاهش اندازه ذرات شده است؛ سرعت چرخشی نیز همانند درصد کامپوزیت تاثیر منفی روی اندازه ذرات دارد.



در این نمونه، پایین بودن کسر حجمی کامپوزیت و سرعت چرخشی اصلی ترین علت بالاتر بودن خروجی نسبت به میانگین مدل هستند. پایین بودن سرعت نفوذ کمی اثر منفی داشته، اما نتوانسته اثر مثبت دو عامل اول را خنثی کند.

اجرای آزمون‌های Friedman و Nemenyi و نتیجه‌گیری

```
Friedman Test: Statistics=10.000, p-value=0.0067

Nemenyi Post-hoc Test (p-values):
```

	XGBoost	RandomForest	SVR
XGBoost	1.000000	0.253784	0.004464
RandomForest	0.253784	1.000000	0.253784
SVR	0.004464	0.253784	1.000000

نتیجه آزمون‌ها

در نتایج پروژه بیان کردیم که میان مدل‌ها تفاوت زیادی وجود دارد و از میان آن‌ها مدل‌های برتر را انتخاب کردیم؛ حال با این آزمون نشان می‌دهیم که این ادعا صرفاً براساس مقایسه معیار R^2 نبوده است.

در نتایج پروژه اذعان کردیم که اکثر خروجی‌ها با مدل‌های Boosting با دقت بالایی قابل پیشبینی هستند و برخی از خروجی‌ها نیز به دلیل سادگی و قابل پیشبینی بودن در رفتار با مدل‌های خطی قابل پیشبینی بودند.

آزمون Friedman و Nemenyi به ما این امکان را دادند که برتری مدل‌های منتخب را به صورت آماری ارزیابی کنیم؛ در نتیجه آزمون مشاهده می‌شود که اختلاف زیادی بین XGBoost و SVR وجود دارد و انتخاب بین این دو مدل، یک انتخاب ساده و بی‌اهمیت نیست.

در این پروژه باوجود تعداد کم نمونه، بدون وقوع بیش‌برازش توانستیم مدل‌هایی را آموزش داده و با تنظیم پارامترها درعین حفظ پایداری، دقت مدل‌ها را افزایش دادیم.

مشاهده محیط MLflow

استفاده از MLflow Tracking به ما اجازه داد که ۱۶ run مختلف را با شفافیت کامل ثبت و مقایسه کنیم، که برای reproducibility و تفسیرپذیری نتایج ضروری بود. همچنین، بهینه‌سازی با Optuna در مقایسه با Grid Search، زمان محاسبات را حدود ۶۰٪ کاهش داد (بدون افت در دقت).

فقط ۷۰٪ از داده‌ها در هر boosting iteration استفاده تا از بیش‌برازش جلوگیری شود و تمام مدل‌ها در نهایت به پایداری خوبی رسیدند.

همچنین انحراف معیار (std) پایین بین Fold ها نشان می‌دهد که این مدل‌ها روی کل داده‌های دیتاست به خوبی تعمیم یافته‌اند (Generalize).

✓ تفاوت جزئی بین عملکرد CV و test set که تقریباً ۷٪ است، نشان‌دهنده تعمیم‌پذیری قابل قبول مدل‌های نهایی است، هرچند بهینه‌سازی بیشتر مثلاً **early stopping** یا افزایش داده می‌تواند این شکاف را کاهش دهد.

